

# 基于 RBF 神经网络模型的电力系统短期负荷预测

周 旭, 来庭煜, 饶佳黎

(三峡大学 电气与新能源学院, 湖北 宜昌 443000)

**摘要:** 电力系统短期负荷对电力企业的经济效益和社会效益都有一定影响。因此文中建立了基于 RBF 神经网络的电力系统短期负荷模型。用历史负荷数据作为训练样本, 用训练好的神经网络进行电力系统短期负荷预测, 并与 BP 神经网络进行对比。RBF 神经网络的平均误差为 2.09%, 最大误差为 4.77%, 相比于 BP 神经网络精确度较高, 有利于电力系统合理地进行调度规划工作。

**关键词:** RBF 神经网络; 短期负荷预测; BP 神经网络

## Short Term Load Forecasting of Power System Based on RBF Neural Network Model

ZHOU Xu, LAI Ting-yu, RAO Jia-li

(College of Electrical Engineering and New Energy, China Three Gorges University, Yichang 443000, China)

**Abstract:** The short-term load of power system has a certain impact on the economic and social benefits of electric power enterprises. Therefore, a short-term load model of power system based on RBF neural network was established in this paper. Using historical load data as training samples, short-term load forecasting of power system was carried out by trained neural network, and compared with BP neural network. The average error of RBF neural network is 2.09%, and the maximum error is 4.77%. Compared with BP neural network, the accuracy of RBF neural network is higher, which is conducive to the rational dispatch planning of power system.

**Key words:** RBF neural network; short-term load forecasting; BP neural network

## 0 引言

电力负荷预测是电力部门的重要工作之一, 准确的负荷预测, 可以经济合理地安排电网内部发电机组的启停, 保持电网运行的安全稳定, 保障社会的正常生产和生活用电<sup>[5]</sup>。

近年来, 构成电力负荷的用电器种类繁多, 受气象条件影响的负荷占比持续增高, 但传统的回归分析法、时间序列法和灰色预测法等预测方法求解存在局限性, 因此本文采用 RBF 神经网络法进行电力系统短期负荷预测, 具有最佳逼近, 预测精度较高的优点, 具有一定实用价值。

## 1 RBF 神经网络

### 1.1 基本原理

RBF 神经网络是由 J. Moody 和 C. Darken 于 20 世纪 80 年代末提出的一种性能良好的单隐层前馈性网络结构<sup>[1]</sup>。其具有学习收敛速度快、最佳逼近、训练简洁以及克服局部最小值问题的性能, 可以根据所给问题确定相应的网络拓扑结构。

它一般由输入层、隐含层和输出层构成。第一层为输入层, 由信号源节点组成, 传递信号到隐层。第二层为隐含层, 隐含层节点的变换函数是对中心点径向对称且衰减的非负非线性函数<sup>[2]</sup>。第三层为输出层, 一般是简单的线性函数, 对输入模式作出响应, 结构如图 1 所示。




图 1 RBF 神经网络结构图

隐含层节点的激活函数对输入激励产生一个局部响应, 输入向量越靠近基函数的中心, 隐含层节点做出的响应越大。隐含层第  $i$  个节点的输出响应为:

$$H_i(x) = \exp\left(-\frac{\|x - C_i\|^2}{2\delta_i^2}\right) \quad j = 1, 2, \dots, k$$

式中,  $x$  是  $n$  维输入向量;  $C_i$  为第  $i$  个隐节点的向量;  $\delta_i$  为第  $i$  个隐节点的宽度,  $k$  为隐节点个数,  $\|x - C_i\|$  为欧几里德范数。

隐含层往输出层为线性的映射, 因此网络的线性输出为单元响应的总和:

$$w_j = \sum_{i=1}^k w_{ij} H_i(x) \quad j = 1, 2, \dots, n$$

式中,  $w_j$  是第  $j$  个输出对输入向量  $x$  的响应向量;  $w_{ij}$  是第  $i$  个隐含层节点与第  $j$  个输出层节点的权值;  $n$  为输出节点个数。

### 1.2 学习算法

学习算法是神经网络问题用于调整权值的一种规则, 也是网络功能实现所必须的。RBF 网络要学习的参数有三个: 基函数的中心  $C_i$ , 隐节点的宽度 (即方差)  $\delta_i$ , 隐含层和输出层的权值  $w_{ij}$ <sup>[3]</sup>。

#### 1.2.1 确定中心 $C_i$

收稿日期: 2018-09-26

作者简介: 周 旭 (1997-), 男, 云南曲靖人, 大学本科, 主要研究方向: 电气工程。

本文使用了  $k$ -均值聚类算法。假设聚类中心有  $N$  个, 且  $C_i(n) (i = 1, 2, \dots, N)$  是第  $n$  次迭代时的中心。

(1) 随机选取  $N$  个不同样本作为  $C_i(0)$ , 迭代步数  $n = 0$ 。

(2) 随机输入训练样本  $M_k$ , 找出离训练样本最近的中心, 即满足:

$$i(X_k) = \operatorname{argmin} ||X_k - C_i(n)|| \quad i = 1, 2, \dots, N$$

$C_i(n)$  表示在第  $n$  次迭代时径向基函数的第  $i$  个中心。

(3) 通过下面的公式对基函数的中心进行调整:

$$C_i(n+1) = \begin{cases} C_i(n) + \eta [X_k(n) - C_i(n)] \\ C_i(n) \end{cases}$$

$\eta$  为学习步长, 且  $0 < \eta < 1$ 。

(4) 判断是否学完所有的训练样本且中心的分布不再变化, 是则结束; 不是则重复上述操作, 直到中心  $C_i$  的改变很小为止。

### 1.2.2 确定方差 $\delta_i$

RBF 神经网络的中心  $C_i$  确定以后, 那么其宽度由下列公式来确定:

$$\delta_i = \frac{d_i}{\sqrt{2n}}$$

式中,  $n$  为隐含层单元的个数,  $d_i$  为所选中心之间的最大距离。

### 1.2.3 确定隐含层和输出层间权值 $w_{ij}$

对采用输出权值的逆伪矩阵法:

$$W_2 = G^+ d$$

式中,  $d$  为训练集中的期望响应向量,  $G^+$  矩阵为  $G$  的逆伪, 矩阵  $G$  的定义为:

$$G = \{g_{qi}\}$$

$$g_{qi} = \exp\left(-\frac{M}{d} ||C_q - C_i||\right)$$

$$q = 1, 2, \dots, Q; N = 1, 2, \dots, M$$

式中,  $C_q$  为第  $q$  个输入样本的向量。

## 2 基于 RBF 神经网络的电力系统短期负荷预测模型

### 2.1 预测流程图

本文对 2014 年某地区的电力系统短期负荷的预测, 建立三层 RBF 神经网络预测模型, 预测方法如图 2。

### 2.2 数据预处理

对电力负荷数据的采集, 每 15 min 一个采样点, 一天 96 点, 量纲为 MW(兆瓦)。直接采用原始数据进行训练会出现神经元饱和现象, 所以在利用神经网络进行训练和测试之前需要对输入 RBF 网络的原始数据进行归一化处理。

根据实验显示, 以适当的方式进行归一化预处理可以使神经网络的收敛速度变快, 准确度变高, 达到更好的预测效果。一般在输入层先将负荷数据及各个特征量归一化到  $[-1, 1]$  中。预测之后, 再将输出值换算回负荷值。

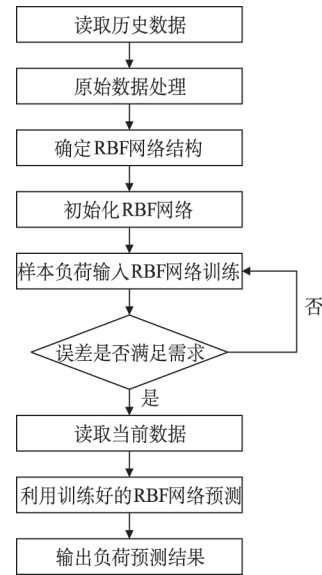


图2 预测流程图

文中所用的归一化方法为:

$$y_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}}$$

式中,  $x_{\max}$ 、 $x_{\min}$  分别为训练样本中输入数据的最大值和最小值,  $y_i$ 、 $x_i$  分别为输入样本归一化前后的值<sup>[4]</sup>。

### 2.3 输入输出量选择

采用 RBF 神经网络模型预测电力负荷, 输入量为预测前一时刻的影响因素, 输出量为后一时刻的预测值, 后一时刻的值必然和前一时刻的值有关, 除非出现特殊情况, 所以将前一天对应时刻的负荷数据作为网络的样本数据。

因此使用第  $n$  天的数据对第  $n-1$  天的电力负荷进行预测, 将所统计年内每日的电力负荷视为一个时间序列  $x(t)$ ,  $t = 1, 2, \dots$ 。其中后一个时间点的和前  $n$  个时间点的相关, 因此设有一函数  $H$  使时间序列  $x(t) = H(x(t-1), x(t-2), \dots, x(t-n))$ , 以 20 年的数据作为基础, 进行反复试验, 用 5 个值对当前值进行预测, 即取  $n = 5$ , 所以神经网络的输入层的神经元数目为 5。RBF 神经网络的输出层由问题决定, 就电力系统短期负荷而言, 输出层神经元数目为 1。

### 2.4 隐含层神经元数目及函数选择

利用 RBF 神经网络进行计算时, 设计隐含层的神经元数量非常重要, 本文利用 Matlab 神经网络工具箱的 newrb 函数创建 RBF 神经网络, 隐含层神经元从零开始逐渐递增, 达到设定的误差要求或最大隐含层神经元数量为止。

## 3 案例分析

利用 Matlab 软件进行编程, 然后以 2014 年 5 月 1 日至 7 月 1 日共 61 天的数据对 RBF 网络电力系统短期负荷预测模型进行检验。设定目标误差为 0.001, 输入层神经元数目设为 5, 输出层神经元数目设计为 1, 径向基函数分布密度 Spread 选值为 0.7, 同时采用 BP 神经网络进行预测, 将两种网络预测结果进行比较, 如表 1 所示。RBF 神经网络与 BP 神经网络的误差曲线分别如图 3、图 4 所示。

表1 预测比较表(部分)

序号	实际值	RBF 预测值	BP 预测值
1	6 812	6 532	7 252
2	6 758	6 759	6 254
3	6 730	6 578	7 227
4	6 657	6 821	6 736
5	6 639	6 728	7 023
6	6 571	6 347	6 933

注:RBF神经网络平均误差为2.09%,最大误差为4.77%;BP神经网络平均误差为5.27%,最大误差为10.52%。




图3 RBF神经网络误差曲线




图4 BP神经网络误差曲线

通过RBF神经网络和BP神经网络误差曲线的对比分析,可得RBF神经网络的准确度更高,相对误差更小,预测的平均误差基本控制在3%以内,可满足电力系统运行要求,为社会创造更高的效益,具有一定实用价值。

#### 4 结束语

文中从RBF神经网络入手,建立了一种电力系统短期负荷预测模型。通过Matlab仿真实验与分析,同时采用RBF神经网络与BP网络训练预测进行比较,实验表明,RBF神经网络的收敛能力更强,预测误差更小、性能更好,在电力系统中具有更高的可行性和实用性。而提高负荷预测的能力将为电力系统调度、实时控制创造良好的条件,有利于合理制定用电规划,提高电力系统的经济效益和社会效益。

#### 参考文献:

- [1] 韩红桂,乔俊飞,薄迎春.基于信息强度的RBF神经网络结构设计研究[J].自动化学报,2012,38(07):1083-1090.
- [2] 勾丽杰,刘家顺.RBF神经网络模型在砂土液化判别中的应用研究[J].长江科学院院报,2013,30(05):76-81.
- [3] 王旭东,邵惠鹤.RBF神经网络理论及其在控制中的应用[J].信息与控制,1997,(04):32-44.
- [4] 解光军,庄镇泉,李海鹰.一种进化RBF神经网络的模型及其训练算法[J].小型微型计算机系统,2001,(11):1315-1317.
- [5] 康重庆,夏清,张伯明.电力系统负荷预测研究综述与发展方向的探讨[J].电力系统自动化,2004,(17):1-11.

(上接第149页)

能力层,提供视频监控、视频分析、大数据分析、运维管理等服务。

(5)应用层(SaaS)是面向用户的应用层,基于平台服务层提供的服务,进行应用系统的开发。

该架构的优势:

(1)视频图像相关信息更全面,信息分析更快更准确

视频云平台可存储PB级容量的视频数据,能够收集到全面的视频信息,对于视频图像信息的检索和分析,能够做出更准确的判断。视频云平台有足够的业务处理能力,能够加速视频图像和大数据分析,更快地分析出结果。

(2)视频应用更高效,更灵活

视频云平台对资源进行统一管理,可实现业务系统对资源的动态调度,对于视频图像要求资源较高的应用,能够及时扩容,能更快的部署业务。

(3)业务系统更智能,更强大

视频云平台统一对视频信息进行资源管理,可以实现多个部门多个应用的联动,对视频图像信息进行结构化和半结构化处理,能够为各种技战法提供准确的数据

支撑,使得技战法不断创新,城市管理更加智能。

#### 3 结论

通过视频云的建设,智慧城市的视频感知能力将得到极大的飞跃和提升,并且满足未来系统架构的趋势以及业务能力、数据量不断扩展的需要。在目前的技术能力下,还需要对海量数据存储和管理的技术、视频智能分析技术、数据的分析和挖掘技术进行持续的研究、开发和改进,确保系统整体业务功能的完整实现。

#### 参考文献:

- [1] 白建华.“视频云”为城市安全保驾护航[J].中国公共安全(综合版),2017,(10):127-129.
- [2] 张冲亚.电子政务云体系下的政府视频云的建设及应用[J].中国安全防范认证,2017,(1):27-30.
- [3] 阎建.紫金新一代视频云解决方案[J].中国金融电脑,2018,(2):90.
- [4] 张力平.视频云发展进入快车道[J].计算机世界,2016,(6):136.
- [5] 鄂梅.城市智能化视频系统建设思路探讨[J].数字通信世界,2016,(11):86-87.